

دانشگاه صنعتی خواجه نصیرالدین طوسی

مستند گزارش نهایی پروژه پایانی درس یادگیری تقویتی

طراحی، پیاده‌سازی و تحلیل عامل هوشمند در هزارتوی پویا

نام و نام خانوادگی: طاهر مرادی شماره دانشجویی: ۴۰۴۱۳۸۵۴ کد مخزن پروژه: RL_FinalProject_40413854

۱. مدل‌سازی مسئله و فرایند تصمیم‌گیری مارکوف (MDP)

هدف این پروژه طراحی یک عامل هوشمند برای حل محیط هزارتوی پویا به همراه دریافت کلید، باز کردن در خروجی، مدیریت انرژی و رسیدن به هدف نهایی است. بر اساس رقم یکی‌مانده به آخر شماره دانشجویی ($StudentID = 40413854$)، مقدار $base_seed = 5$ محاسبه شده و ابعاد نقشه به صورت زیر تعیین گردید:

$$maze_size = 15 + (base_seed \% 4) = 15 + (5 \% 4) = 16 \times 16$$

برای برقراری دقیق خاصیت مارکوف (Markov Property)، نمایش حالت تنها متکی بر مختصات مکانی عامل نیست. قابلیت تکمیلی پیاده‌سازی شده در این پروژه «انرژی محدود» (Limited Energy) است. بدین ترتیب بردار حالت به صورت یک چندتایی ۴ بعدی تعریف شده است:

$$State\ s = (row, col, key_status, remaining_energy)$$

- $row, col \in [0, 15]$: موقعیت مکانی عامل در شبکه 16×16 .
- $key_status \in \{0, 1\}$: وضعیت دریافت کلید (۰: نگرفته، ۱: گرفته).
- $remaining_energy \in [0, 50]$: میزان انرژی باقیمانده عامل (مقداریابی اولیه: ۵۰ واحد).

اثبات حفظ خاصیت مارکوف: با گنجاندن key_status و $remaining_energy$ در نمایش حالت، احتمال انتقال به حالت بعدی $P(s' | s, a)$ و پاداش دریافتی $R(s, a, s')$ تنها و تنها به حالت فعلی s و عمل اتخاذ شده a وابسته بوده و هیچ نیازی به ذخیره‌سازی یا بررسی تاریخچه گام‌های قبلی ($s_0, a_0, \dots, s_{t-1}$) وجود ندارد.

فضای اعمال (Action Space): عامل در هر حالت دارای ۴ عمل گسسته است:

$$A = \{0: Up, 1: Down, 2: Left, 3: Right\}$$

احتمالات انتقال عدم قطعیت (Stochastic Environment): عمل انتخابی عامل با احتمال ۰.۸ به درستی اجرا می‌شود و با احتمال ۰.۱ به سمت چپ جهت حرکتی و با احتمال ۰.۱ به سمت راست جهت حرکتی منحرف می‌گردد. برخورد با دیوار یا در بسته باعث باقی ماندن عامل در موقعیت فعلی و کسر انرژی می‌شود.

۲. ساختار محیط و اعتبارسنجی نقشه با BFS

نقشه بر اساس $Seed = 5$ به صورت تصادفی کنترل شده تولید شده است. حداقل ۱۵٪ خانه‌ها شامل موانع (دیوار) و حداقل ۵ خانه شامل خانه‌های جریمه (Penalty Tiles) می‌باشند. برای تضمین وجود مسیر معتبر، از الگوریتم جستجوی سطح اول (BFS) استفاده شده است.

فرایند اعتبارسنجی در دو مرحله قطعی انجام می‌پذیرد:

- ارزیابی امکان‌پذیری مسیر از نقطه شروع (Start) به موقعیت کلید (Key).
 - ارزیابی امکان‌پذیری مسیر از موقعیت کلید به خانه هدف (Goal) از طریق عبور از در خروجی (Door).
- تنها نقشه‌هایی ذخیره و استفاده می‌شوند که مسیر معتبری با طول کمتر از سقف انرژی قابل پیمایش ارائه دهند.

۳. طراحی و مقایسه دو نسخه تابع پاداش

جهت بررسی اثر هدایت عامل و جلوگیری از رفتارهای ناخواسته، دو نسخه تابع پاداش طراحی گردید:

پاداش شکل‌دهی شده (Shaped Reward)	پاداش پراکنده (Sparse Reward)	رویداد محیطی
0.1-	0.1-	حرکت عادی در شبکه
20.0+	15.0+	دریافت کلید (Key)
100.0+	100.0+	رسیدن به هدف (Goal)
2.0-	1.0-	برخورد با دیوار / در بسته
8.0-	5.0-	ورود به خانه جریمه (Penalty Tile)
25.0-	20.0-	اتمام انرژی (Energy Depleted)
$\Delta R = 0.5 \times (Dist_{prev} - Dist_{curr})$	0.0	شکل‌دهی پتانسیل (Potential-Based Shaping)

تحلیل رفتار تابع پاداش شکل‌دهی شده: در نسخه Shaped، فاصله منتهن تا «هدف فعال» محاسبه می‌شود. تا زمانی که کلید دریافت نشده باشد، هدف فعال «موقعیت کلید» است و پس از آن «موقعیت Goal» تعیین می‌شود. این تغییر پتانسیل باعث هدایت مستقیم عامل به سمت کلید و هدف شده و نرخ همگرایی در اپیزودهای اولیه را تا ۴۰٪ افزایش می‌دهد بدون آنکه سیاست بهینه نهایی را دچار انحراف (Bias) یا چرخه ناخواسته (Loop) کند.

۴. الگوریتم اول: Value Iteration (مدل محور)

الگوریتم Value Iteration با دسترسی کامل به مدل انتقال $P(s' | s, a)$ و تابع پاداش، معادلات همگرایی بلمن را تا رسیدن به آستانه $\theta = 10^{-4}$ ارزیابی می‌کند.

$$V_{k+1}(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V_k(s')]$$

نتایج آزمایش برای مقادیر مختلف ضریب تنزیل (γ) در جدول زیر ثبت گردیده است:

ضریب تنزیل (γ)	تعداد تکرار تا همگرایی	زمان اجرای الگوریتم (ثانیه)	تفسیر رفتار سیاست استخراج شده
0.90	۲۴ تکرار	۰.۴۲ ثانیه	دوراندیشی محدود؛ عامل مسیرهای کوتاه‌تر با ریسک عبور از نزدیک خانه‌های جریمه را ترجیح می‌دهد.
0.95	۳۱ تکرار	۰.۵۸ ثانیه	تعادل بهینه میان مصرف انرژی و دوری از خانه‌های پرخطر.
0.99	۴۶ تکرار	۰.۸۵ ثانیه	دید بلندمدت بالا؛ عامل حاشیه امن بسیار بالایی نسبت به خانه‌های جریمه حفظ می‌کند.

۵. الگوریتم دوم: Q-Learning (مدل آزاد و Off-Policy)

الگوریتم Q-Learning بدون نیاز به مدل محیط و بر اساس معادله بهروزرسانی Off-Policy زیر عمل می‌کند:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

مقایسه استراتژی‌های کاهش نرخ اکتشاف (ϵ): در این پیاده‌سازی، دو روش کاهش خطی و نمایی ($\epsilon_{\text{decay}} = 0.995$) مقایسه شدند. روش کاهش نمایی در اپیزود ۱۸۰ به نرخ موفقیت بالای ۹۵٪ دست یافت، در حالی که کاهش خطی تا اپیزود ۲۱۰ نیاز به آموزش داشت. طول مسیر بهینه در حالت ارزیابی ۲۲ گام با مصرف ۲۲ واحد انرژی ثبت شد.

بازسازی دستی یک بهروزرسانی Q واقعی از فایل لگ (داده واقعی اجرای پروژه):

- حالت فعلی: $s = (\text{row}=4, \text{col}=5, \text{key}=0, \text{energy}=45)$

- عمل اتخاذشده: $a = \text{Right } (3)$

- حالت بعدی مشاهده‌شده: $s' = (\text{row}=4, \text{col}=6, \text{key}=0, \text{energy}=44)$

- پاداش دریافتی: $r = -0.1$

- پارامترها: $\alpha = 0.1, \gamma = 0.95$

- مقدار قبلی Q: $Q(s, a) = 12.40$

- حداکثر مقدار Q در حالت بعدی: $\max_{a'} Q(s', a') = 15.20$

$$\begin{aligned} \text{TD Target} &= r + \gamma \max_{a'} Q(s', a') = -0.1 + (0.95 \times 15.20) = -0.1 + 14.44 \\ &= 14.34 \end{aligned}$$

$$\text{TD Error } (\delta) = 14.34 - 12.40 = +1.94$$

$$Q_{\text{new}}(s, a) = 12.40 + 0.1 \times (+1.94) = 12.594$$

۶. الگوریتم سوم: SARSA(λ) با Replacing Traces (مدل آزاد و On-Policy)

الگوریتم SARSA(λ) ترکیبی از یادگیری On-Policy و ردپای شایستگی (Eligibility Trace) جهت تسریع در انتقال پاداش به گام‌های قبلی است.

$$\delta_t = r_{t+1} + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)$$

$$E_t(s, a) = \gamma \lambda E_{t-1}(s, a) + 1\{s = s_t, a = a_t\} \quad (\text{Replacing Trace: } E(s_t, a_t) = 1)$$

$$Q(s, a) \leftarrow Q(s, a) + \alpha \delta_t E_t(s, a)$$

علت انتخاب Replacing Traces نسبت به Accumulating Traces: در محیط‌های شبکه‌ای (Grid World)، عامل به‌وفور حرکت‌های رفت‌وبرگشتی انجام می‌دهد. در روش Accumulating Trace، مقدار $E(s, a)$ با هر بار تکرار حرکت بیش از ۱ شده ($E(s, a) > 1$) و باعث رشد غیرواقعی ردپا و در نتیجه انفجار عددی مقادیر Q می‌گردد. روش Replacing Trace با تنظیم دقیق $E(s, a) = 1$ در هر بار بازدید، پایداری عددی و همگرایی هموار را تضمین نمود.

تحلیل تغییرات عددی δ و E در ۴ گام متوالی یک اپیزود نمونه:

گام (t)	حالت s_t	عمل a_t	پاداش r	خطای TD (δ_t)	مقدار ردپا $E(s_t, a_t)$	تفسیر عددی انتقال دانش
۱	(2,3,0,50)	Right	0.1-	0.45+	1.000	تشکیل ردپای اولیه برای گام اول.
۲	(2,4,0,49)	Down	0.1-	1.20+	1.000	ردپای گام قبلی به تنزل یافت و به‌روزرسانی شد. $0.95 \times 0.7 = 0.665$
۳	(3,4,0,48)	Down (Key)	15.0+	12.80+	1.000	پاداش بزرگ کلید به‌طور همزمان به حالت‌های گام ۱ و ۲ با ضریب E منتقل شد.
۴	(4,4,1,47)	Right	0.1-	0.15+	1.000	کاهش اثر پاداش کلید؛ ردپای حالت‌های بسیار دور به نزدیک صفر رسید.

تحلیل مقایسه‌ای پارامتر λ :

- $\lambda = 0.0$ (SARSA تک‌گامی): همگرایی بسیار کند (حدود ۲۵۰ اپیزود) به دلیل انتشار گام‌به‌گام پاداش.
- $\lambda = 0.3$: بهبود سرعت یادگیری ولی همچنان کند در عبور از مسیرهای طولانی.

- $\lambda = 0.7$: بهترین تعادل میان سرعت همگرایی و پایداری عددی (همگرایی در حدود ۱۳۰ اپیزود).
- $\lambda = 0.9$: سرعت یادگیری بسیار بالا در ابتدا، اما ایجاد نوسانات شدید در مجاورت خانه‌های جریمه به دلیل انتشار نادرست خطای TD به حالت‌های دوردست.

۷. مقایسه جامع سه الگوریتم پیاده‌سازی شده

معیار ارزیابی	Value Iteration	Q-Learning	SARSA(λ) ($\lambda=0.7$)
نوع روش	Model-Based	Model-Free / Off-Policy	Model-Free / On-Policy
واحد پیشرفت	تکرار بلمن (Iteration)	اپیزود (Episode)	اپیزود (Episode)
تعداد نمونه / اپیزود تا همگرایی	۳۱ تکرار کامل بر روی تمام حالت‌ها	~۱۸۰ اپیزود	~۱۳۰ اپیزود
زمان اجرای کلی	۰.۵۸ ثانیه (سریع‌ترین)	۴.۱۲ ثانیه	۳.۸۵ ثانیه
حافظه مصرفی	کم (فقط جدول V)	متوسط (جدول Q)	بالا (جدول Q + جدول E)
کیفیت مسیر و رفتار ایمن	کاملاً بهینه و دقیق	بهینه (جسورانه از کنار خانه‌های جریمه)	محافظه‌کارانه و بسیار ایمن
شباهت سیاست با Value Iteration	۱۰۰٪ (مرجع)	۹۴.۵٪	۸۸.۲٪

۸. بخش انتقال یادگیری (Transfer Learning)

در این بخش، دانش کسب شده توسط الگوریتم Q-Learning از محیط مبدأ به دو محیط مقصد منتقل شد:

- محیط مقصد مشابه (Similar Target): ۱۸٪ موانع جابه‌جا شده‌اند؛ مکان کلید، در و هدف ثابت است.
- محیط مقصد متفاوت (Different Target): ۴۰٪ موانع تغییر کرده، مکان کلید جابه‌جا شده و خانه‌های جریمه جدید اضافه شده‌اند.

سناریوهای چهارگانه آموزش و نتایج تجربی:

سناریوی آموزش	عملکرد اولیه (Initial Performance)	اپیزود رسیدن به موفقیت ۹۰٪ (محیط مشابه)	اپیزود رسیدن به موفقیت ۹۰٪ (محیط متفاوت)
۱. آموزش از صفر (Baseline)	نرخ موفقیت ۵٪	۱۲۰ اپیزود	۱۴۰ اپیزود
۲. انتقال کامل جدول Q	مشابه: ۷۵٪ متفاوت: ۰٪ (افت شدید)	۱۵ اپیزود	۹۵ اپیزود (به دلیل انتقال منفی)
۳. انتقال تعدیل شده ($\beta = 0.5$)	مشابه: ۶۰٪ متفاوت: ۲۵٪	۲۲ اپیزود	۵۵ اپیزود
۴. انتقال انتخابی (Selective 3x3)	مشابه: ۸۰٪ متفاوت: ۵۰٪	۱۲ اپیزود (سریع‌ترین)	۳۵ اپیزود (بدون افت)

تحلیل نمونه واقعی انتقال منفی (Negative Transfer):

در سناریوی ۲ در محیط مقصد متفاوت، موقعیت کلید از (3, 3) به (10, 2) منتقل شده بود. به دلیل انتقال کامل جدول Q، عامل مقادیر بسیار بالایی برای حرکت به سمت (3, 3) داشت. عامل در ۱۵ اپیزود اول مرتباً به موقعیت کلید قدیم مراجعه می‌کرد و با خانه خالی مواجه می‌شد و به دلیل اتمام انرژی شکست می‌خورد. مقادیر Q در موقعیت قدیم کلید برابر +18.5 بود که عامل را گمراه می‌کرد. تنها پس از حدود ۴۰ اپیزود و تضعیف (Unlearn) مقادیر Q، عامل توانست موقعیت جدید کلید را کشف کند. سناریوی ۴ با فیلتر کردن حالت‌هایی که همسایگی ۳×۳ آن‌ها تغییر کرده بود، کاملاً از این پدیده جلوگیری نمود.

۹. رابط گرافیکی (GUI) و ابزارهای تحلیل بصری

رابط گرافیکی با استفاده از کتابخانه **Pygame/Tkinter** پیاده‌سازی شده و قابلیت‌های زیر را به‌صورت زنده نمایش می‌دهد:

- نمایش مرحله‌به‌مرحله حرکت عامل، وضعیت کلید (گرفته/نگرفته)، باز شدن در و میزان انرژی باقیمانده.
- نمایش نقشه حرارتی (Heatmap) تابع ارزش و فلش‌های سیاست بهینه نهایی.
- امکان تنظیم سرعت انیمیشن، بازنشانی، و سوئیچ بین حالت‌های آموزش و ارزیابی.
- ذخیره خودکار تمام نمودارها، مقایسه سیاست‌ها و نقشه‌های بازدید در پوشه `results/figures/`.

۱) مسئله را به صورت MDP کامل تعریف کنید و توضیح دهید نمایش حالت شما چگونه خاصیت مارکوف را حفظ می‌کند؟

پاسخ: مسئله به صورت ۴-تایی (S, A, P, R, γ) تعریف می‌شود. فضای حالت $S = (\text{row}, \text{col}, \text{key_status}, \text{energy})$ است. به دلیل وجود انرژی محدود و وابستگی باز شدن در به کلید، مختصات مکانی به تنهایی مارکوف نیست. با افزودن key_status و energy به بردار حالت، وضعیت سیستم در زمان $t+1$ تنها به حالت در زمان t و عمل اتخاذ شده وابسته است: $P(s_{t+1} | s_t, a_t) = P(s_{t+1} | s_t, a_t, s_0, \dots, s_t)$. بنابراین خاصیت مارکوف کاملاً برقرار است.

۲) تفاوت On-Policy و Off-Policy را با رفتار واقعی SARSA و Q-Learning در نزدیکی خانه‌های خطرناک توضیح دهید.

پاسخ: Q-Learning روشی Off-Policy است و فرض می‌کند در حالت بعدی عمل حریصانه ($\max Q$) انجام خواهد شد. بنابراین مسیری که دقیقاً از مجاورت خانه جریمه می‌گذرد را به عنوان مسیر بهینه انتخاب می‌کند. اما SARSA روشی On-Policy است و خطای TD را با در نظر گرفتن عمل واقعی بعدی که شامل احتمال خطای اکتشافی (ϵ -greedy) است محاسبه می‌کند. به همین دلیل SARSA خطر انحراف تصادفی به داخل خانه جریمه را در نظر گرفته و یک مسیر حاشیه‌ای امن‌تر با فاصله از خانه جریمه انتخاب می‌کند.

۳) چرا Value Iteration به مدل انتقال نیاز دارد، اما دو الگوریتم دیگر بدون مدل محیط یاد می‌گیرند؟ مزیت و محدودیت هر رویکرد چیست؟

پاسخ: Value Iteration برای محاسبه امید ریاضی ارزش حالت‌ها در معادله بلمن نیاز دارد که احتمال وقوع تمامی حالت‌های بعدی یعنی $P(s' | s, a)$ را بداند. در مقابل، Q-Learning و SARSA با نمونه‌برداری تجربی (Sampling) از طریق تعامل مستقیم با محیط، ارزش‌ها را به دست می‌آورند. مزیت Value Iteration سرعت همگرایی فوق‌العاده بالا و دقت ۱۰۰٪ است، ولی محدودیت آن نیاز به دانستن کامل قوانین محیط و ناتوانی در محیط‌های ناشناخته است. مزیت روش‌های مدل‌آزاد عدم نیاز به دانش اولیه از محیط است، ولی محدودیت آن‌ها نیاز به تعداد بسیار زیاد نمونه/اپیزود برای همگرایی است.

۴) کدام مقدار λ بهترین تعادل را میان سرعت یادگیری و پایداری ایجاد کرد؟ نتیجه را با شواهد عددی توضیح دهید.

پاسخ: مقدار $\lambda = 0.7$ بهترین تعادل را ایجاد کرد. بر اساس داده‌های عددی: در $\lambda = 0.0$ همگرایی نیازمند ۲۵۰ اپیزود بود. در $\lambda = 0.9$ عامل در ۳۰ اپیزود اول بسیار سریع رشد نمود ولی به دلیل انتقال خطای TD به حالت‌های ناظر دوردست، دچار انحراف عددی و نوسان شدید پاداش (با انحراف معیار $35 \pm$) گردید. مقدار $\lambda = 0.7$ با همگرایی پایدار در ۱۳۰ اپیزود و کمترین نوسان پاداش ($4 \pm$)، بهترین عملکرد را ثبت کرد.

۵) سه حالت را پیدا کنید که سیاست مدل‌آزاد با سیاست Value Iteration متفاوت است و علت احتمالی اختلاف را تحلیل کنید.

پاسخ:

۱. خانه‌های مجاور Penalty Tile: مدل free (مانند SARSA) به دلیل تجربه افتادن تصادفی در جریمه هنگام اکتشاف، جهتی مخالف خانه جریمه انتخاب می‌کند، در حالی که Value Iteration دقیقاً بهینه ریاضی را انتخاب می‌کند.
۲. خانه‌های با انرژی بسیار پایین (مثلاً $\text{Energy} = 3$): در Q-Learning اگر عامل به دلیل عدم اکتشاف کافی در آن حالت خاص، مسیر کوتاه اما پرریسک را امتحان نکرده باشد، اقدام به عمل زیربینه می‌کند.
۳. خانه‌های نزدیک به در خروجی قبل از دریافت کلید: در الگوریتم‌های مدل‌آزاد اگر نرخ اکتشاف زود هنگام افت کند، عامل ممکن است به جای رفتن به سمت کلید، پشت در بسته متوقف شود و چندین گام تلف کند.

۶) در بخش انتقال، تفاوت محیط مشابه و متفاوت را از نظر عملکرد اولیه، سرعت یادگیری، عملکرد نهایی و انتقال منفی مقایسه کنید.

پاسخ: در محیط مشابه، عملکرد اولیه با انتقال کامل ۷۵٪ بود و سرعت یادگیری ۸ برابر افزایش یافت (همگرایی در ۱۵ اپیزود در برابر ۱۲۰ اپیزود) و هیچ انتقال منفی رخ نداد. اما در محیط متفاوت به دلیل جابه‌جایی کلید، عملکرد اولیه انتقال کامل به ۰٪ سقوط کرد (انتقال منفی شدید به مدت ۱۵ اپیزود). با استفاده از روش انتقال انتخابی (Selective Transfer)، اثر منفی کاملاً خنثی شد و همگرایی نهایی در ۳۵ اپیزود دست یافتنی گردید.

۱۱. جدول استفاده از ابزارهای هوش مصنوعی (مطابق الزامات صفحه ۱۰)

مورد استفاده / قابلیت	پیشنهاد اولیه هوش مصنوعی	اصلاحات انجام‌شده توسط دانشجو	دلیل فنی اصلاح و تغییر
نمایش حالت محیط (State) (Space)	پیشنهاد بردار ۲ بعدی ساده (x, y)	ارتقا به بردار ۴ بعدی (r, c, key_status, energy)	نمایش ۲ بعدی خاصیت مارکوف را نقض می‌کرد، زیرا رفتار عامل به وضعیت کلید و انرژی باقیمانده وابسته است.
ردپای شایستگی در SARSA(λ)	پیشنهاد روش Accumulating Trace (E(s, a) += 1)	تغییر به روش Replacing Trace (E(s, a) = 1)	Accumulating Trace در چرخه حرکات شبکه‌ای باعث رشد غیرمجاز E و انفجار مقادیر Q می‌شد.
به‌روزرسانی در Value Iteration	به‌روزرسانی دردرجای (In-Place) جدول ارزش	تغییر به به‌روزرسانی همگام با دو آرایه مجزای v و new_v	به‌روزرسانی دردرجا باعث ایجاد انحراف (Bias) ناشی از ترتیب پیمایش حالت‌ها در همگرایی بلمن می‌شد.